


Übung 3 - Daten II

Aufgabe 1 - Verkaufszahlen erhöhen mit dem Will-Rogers-Phänomen (5)

Einen (leider mittlerweile) bekannten Trick erfolgreicher Verkaufsleiter können Sie hier finden:

Der Regionsleiter der Region *Südhessen/Stadt* eines Pharmaunternehmens soll nach der Kündigung eines Kollegen die benachbarte Region *Südhessen/Land* mit übernehmen. Natürlich sind die Umsätze in den ländlichen Regionen kleiner als in der Stadt. Er will aber seinen Vorgesetzten zeigen, dass er sofort die Zahlen erhöhen kann. Die Umsätze der Verschreibungen in den Bezirken sind in der Tabelle *pharma.txt* gespeichert.

Als erfahrener Vertriebsmann weiß er was zu tun ist: Er erkennt, dass der Main-Taunus-Kreis in der falschen Region ist und legt ihn zum Beginn des zweiten Quartals in die ländliche Region.



- Berechnen Sie die durchschnittlichen Verschreibungen pro Arzt einzeln in beiden Regionen, jeweils in Q1 vor und in Q2 nach der Umlegung.
- Berechnen Sie die die durchschnittlichen Verschreibungen pro Arzt in beiden Quartalen über alle Bezirke gemeinsam.
 - Erklären Sie den Effekt!

Tipp: `groupby`

In []:

Aufgabe 2 - Ein Raucherleben (5)

Eine Studie untersucht die Überlebenschancen von Rauchern und Nichtrauchern. Dazu wurden Raucher und Nichtraucher erfasst und 20 Jahre später überprüft ob diese noch leben. Die Ergebnisse sind in der Tabelle wiedergegeben:

Tabelle 1: Altersgruppe 55 bis 64 Jahre

	Raucher	Nichtraucher
Anzahl	115	121
Überlebende nach 20 Jahren	64	81

Tabelle 2: Altersgruppe 65 bis 74 Jahre

	Raucher	Nichtraucher
Anzahl	36	129
Überlebende nach 20 Jahren	7	28

- Berechnen Sie für jede Altersgruppe die Überlebenswahrscheinlichkeit für Raucher und Nichtraucher.
- Berechnen Sie die Überlebenswahrscheinlichkeit für Raucher und Nichtraucher in der Gesamtgruppe.
- Versuchen sie die Ergebnisse zu erklären!

In []:

Aufgabe 3 (10)

Laden Sie den Datensatz *_winefinal.txt* aus Moodle und verschaffen Sie sich einen Überblick über die Daten. Der Datensatz enthält Analysenergebnisse von Weinen, eines Weinbaugebiets. Als Klassen sind verschiedene Weingüter codiert, die jeweils unterschiedliche Rebsorten anbauen. Der Datensatz enthält eine Probe mit unbekannter Herkunft. Ziel ist es, den unbekannten Wein korrekt zuzuordnen.

a) Lesen Sie den Datensatz in Python ein

In []:

b) Nach welchen Merkmalen kann man die Weingüter am besten separieren (Tipp: `pairplot`)

In []:

c) Normalisieren Sie die Daten mit dem `StandardScaler` . Was macht der `StandardScaler` ? Was müssen Sie im Vorfeld eventuell beachten, und warum?

In []:

d) Führen Sie eine Dimensionsreduktion mittels PCA auf den Daten aus und visualisieren Sie die Daten in einem 2 D oder 3 D Scatterplot. Färben Sie die Punkte nach den Weingütern (Tipp: `seaborn`). Schreiben Sie den Anteil an erklärter Varianz mit an die Achsen.

In []:

e) Welche Attribute haben jeweils einen großen Einfluss auf die ersten zwei Hauptkomponenten? Gibt es Überlappungen mit den Attributen, die Sie in b) identifiziert haben?

In []:

f) Visualisieren Sie den Anteil an erklärter Varianz je Hauptkomponente und erklären Sie den Plot.

In []:

g) Versuchen Sie durch Visualisierung die unbekannte Probe einem Weingut zuzuordnen.

In []: