

Übung 5

Aufgabe 1 (10)

Verwenden Sie den Genexpressionsdatensatz aus Übung 4 (gefiltert nach regulierten Genen & skaliert, aber **nicht** PCA-transformiert) und versuchen Sie die Daten mit dem k-means Clusteralgorithmus zu Clustern.

a) Initialisieren Sie dabei die Cluster zufällig und lassen Sie den Algorithmus für alle $k \in [2,10]$ je 5 mal laufen. Visualisieren Sie die Inertia (WSS) mit einem Elbowplot, zeichnen Sie hier auch die Standardabweichung ein. Warum macht es Sinn, nicht einfach nur den Mittelwert der Inertia je k zu zeigen? (Hinweis: Initialisieren Sie die Cluster zufällig und verwenden Sie für diese Aufgabe kmeans++ maximal als Zusatz)

In []:

b) Lassen Sie sich die Silhouette-Scores anzeigen (gemittelt für jedes k mit Standardabweichung).

In []:

c) Diskutieren Sie Ihre Ergebnisse - was ist das richtige k? Kann die Inertia gleich 0 sein? Falls ja, wann?

In []:

d) Visualisieren Sie die Cluster für k=2 in der PCA-Darstellung. Stellen Sie dabei auch die Centroide dar. Sie erhalten Sie durch `centers=k_means.cluster_centers_`

In []:

e) Erstellen Sie k=2 Cluster für die PCA-Daten und Visualisieren Sie die Ergebnisse. Vergleichen Sie die Ergebnisse mit denen vorherigen.

In []:

Aufgabe 2: k-Medoids (5)

Verwenden Sie den Iris-Datensatz.

a) Visualisieren Sie die Daten mittels PCA, farblich nach Gattung markiert.

In []:

b) Clustern Sie die skalierten Daten mit dem k-Means Algorithmus. Visualisieren Sie die Ergebnisse mittels PCA (Form Spezies, Farbe Cluster).

In []:

c) Verwenden Sie nun den k-medoids Algorithmus. Clustern und Visualisieren Sie die Daten erneut.

In []: