

Übung 7: Klassifikation

Aufgabe 1 ROC Kurve (10)

Angenommen Sie haben ein binäres Klassifizierungsproblem, für das Sie einen Klassifizierungsalgorithmus trainiert haben.

Hinweis: Die Berechnungen der Metriken sollen selbst implementiert werden. Es sollen also **keine** Bibliotheken wie *scikit-learn* etc. verwendet werden.

a) Simulieren Sie je 100 Ergebnisse für einen

- perfekten Klassifizierer
- einen immer falschen Klassifizierer
- einen Klassifizierer, der nur rät (zieht Wahrsch. aus Gleichverteilung)
- einen Klassifizierer, mit guter Sensitivität, aber schlechter Spezifität

Hinweis: Damit eine Schwelle t Sinn macht: Arbeiten Sie wie in der VL gezeigt mit **Wahrscheinlichkeiten**, die sich auch von 0 und 1 unterscheiden sollen!! (Auch für den perfekten Klassifizierer - verwenden Sie bitte Wahrscheinlichkeiten, die nicht alle exakt 0 oder 1 sind (auch wenn er dann nicht mehr ganz so perfekt ist ;))).

b) Berechnen Sie für die Klassifizierer die Confusion-Matrix und folgende Kenngrößen, wobei Sie eine Klassifikationsschwelle von $t=0,5$ verwenden:

- Sensitivität
- Spezifität
- Accuracy
- MCC
- F1-Score

In []:

c) Berechnen Sie für unterschiedliche Schwellen TPR und FPR und zeichnen Sie für jeden der Klassifikatoren die ROC-Kurve (ohne fertige Bibliotheken für ROC/AUC Kurven zu verwenden).

In []:

Aufgabe 2 Eigener Klassifizierer (10)

Der Datensatz PSA enthält Die PSA-Werte von 370 Patienten mit der jeweiligen (vereinfachten) Diagnose: krank oder gesund. (PSA:prostataspezifische Antigen)

Versuchen Sie mithilfe einer ROC einen vernünftigen PSA-Grenzwert zu ermitteln, ab dem eine Behandlung oder zumindest eine weiterführende Diagnose durchgeführt werden sollte (Achtung: Behandlung heißt Operation und Bestrahlung - also nichts, was man so zum Spaß macht! Auch die weiterführende Diagnose durch eine Prostatabiopsie ist nicht lustig, sondern sehr gefährlich und sollte nicht unnötigerweise gemacht werden!). Erstellen Sie eine aussagekräftige Visualisierung, die Ihnen hilft Ihre Entscheidung zu begründen bzw. zu verteidigen. Beachten Sie, dass (theoretisch) ein PSA-Screening bei jedem Mann ab einem Alter von ca. 40 Jahren regelmäßig gemacht werden sollte. Das wird deshalb in Deutschland jedes Jahr bei ca. 25 Mio Männern gemacht. Die Inzidenz von Prostatakrebs (neu diagnostizierte Erkrankungen) beträgt ca. 70000 pro Jahr.(A.Dominik)

Sie können hier beliebige Bibliotheken verwenden.

a) Visualisieren Sie hierfür zunächst die Daten, so dass Sie genauere Informationen über die Verteilungen erhalten.

In []:

b) Wie viele kranke und wie viele gesunde Menschen befinden sich in Ihrem Datensatz?

In []:

c) Verwenden Sie unterschiedliche PSA-Grenzwerte und ermitteln Sie die ROC-Kurve (visualisieren Sie sie).

In []:

d) Legen Sie einen geeigneten Grenzwert fest. Schreiben Sie dafür den Schwellwert an jeden Punkt in der ROC-Kurve und überlegen Sie was laut Aufgabenstellung der beste Wert wäre.

In []:

e) Der Youden-Index ist ein Wert, der hilft in der ROC-Kurve den optimalen Schwellenwert zu finden. Dabei ist der optimale Schwellenwert der Wert, der dem maximalen Youden-Index zugeordnet werden kann.

Der Youden-Index J ist wie folgt definiert:

$$J = \text{Sensitivität} + \text{Spezifität} - 1$$

Die Spezifität ist die TNR , die Sensitivität die TPR . Es gilt $FPR = 1 - TNR$. Für die Aufgaben müssen Sie keine neuen Kenngrößen berechnen, Sie können mit der gegebenen Hilfestellung J durch TPR und FPR berechnen.

In []:

f) Wie groß ist bei Ihrem Entscheidungskriterium die Gesamtzahl

- Korrekt positiv Diagnostizierter?
- Falsch positiv Diagnostizierter (die unnötigerweise zur Biopsie müssen)?
- Korrekt negativ Diagnostizierter?
- Falsch negativ Diagnostizierter (deren Krankheit nicht erkannt wird)?

In []: