

Übung 8

Aufgabe 1 KNN-Algorithmus (10)

Verwenden Sie den unteren Code um sich einen Datensatz zu erstellen.

a) Erstellen Sie ein Scatterplot der Daten, färben Sie die Punkte nach den Klassen.

```
In [1]: import numpy as np
import matplotlib.pyplot as plt

from sklearn.datasets import make_moons
from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy_score

In [2]: X, y = make_moons(
    n_samples=1000,
    noise=0.4,
    random_state=42
)

X.shape

Out[2]: (1000, 2)
```

b) Nutzen Sie die `train_test_split()` Funktion, um sich Trainings- und Testdaten zu generieren. Teilen Sie die Daten dabei in 70% Train und 30% Test ein.

```
In [ ]:
```

c) Verwenden Sie $K = [1, 3, 5, 10, 20, 50, 100, 124]$ und *trainieren* Sie den KNN mit den Trainingsdaten und testen Sie ihn anschließend mit den Testdaten. Speichern Sie dabei als Fehlerfunktion 1-Accuracy für den jeweiligen Lauf (einzeln für Train und Test).

```
In [ ]:
```

d) Visualisieren Sie das Ergebnis sinnvoll. Welches K würden Sie wählen?

```
In [ ]:
```

e) Visualisieren Sie die Decision Surfaces für jedes K . Verwenden Sie hierfür gerne den Code aus https://data-science-crashkurs.de/chapters/kapitel_07.html, es kann sein, dass Sie ein paar Anpassungen machen müssen.

```
In [ ]:
```

f) Erklären Sie das Ergebnis im Sinne von Bias-Variance-Tradeoff.

```
In [ ]:
```

Aufgabe 2: Schummeln mit Train-Test-Split (5)

Verwenden Sie die Daten von Aufgabe 1.

a) Verwenden Sie den KNN-Klassifikator mit dem besten K aus Aufgabe 1. Lassen Sie den `train-test-split` mit unterschiedlichen Seeds laufen. Visualisieren Sie die Accuracy für die unterschiedlichen Läufe (gerne Boxplot, je eines für Train- und Testdaten).

```
In [ ]:
```

b) Was sind Ihre besten Ergebniss, was Ihre schlechtesten? Was folgern Sie daraus für die Vertrauenswürdigkeit von Ergebnissen aus Machine Learning Experimenten?

```
In [ ]:
```

Zusatzaufgabe: Cross Validation (10)

a) Eigentlich ist das Vorgehen von Aufgabe 1 für die Findung des besten Ks falsch. Warum?

```
In [ ]:
```

b) Verwenden Sie die Trainingsdaten von Aufgabe 1 - erstellen Sie eine *5 fold cross validation* (selbst implementiert, nicht mit fertigen sklearn routinen) und führen Sie Aufgabe 1 (außer d)) erneut aus. Für den Fehlerplot, visualisieren Sie nun bitte Mittelwert und Standardabweichungen.

```
In [ ]:
```