

Übung 9

Entscheidungsbäume

Aufgabe 1: Weine Klassifizieren (10)

Sie verwenden den Ihnen schon bekannten Wein-Datensatz *_winefinal.txt*. Ziel ist es anhand der Attribute die Weingüter vorherzusagen.

a) Daten verstehen

- Verschaffen Sie sich einen geeigneten Überblick über die Daten (Visualisierung)
- Stellen Sie mind. 3 Bedingungen auf, nach denen Sie die Daten in einem Entscheidungsbaum für die Klassifizierung separieren würden

Hinweis: Entfernen Sie den Wein, der als "unbekannt" gelabelt wurde.

In []:

b) Teilen Sie die Daten in 1/3 Test und 2/3 Trainingsdaten auf. Verwenden Sie hierfür die Methode *_train_testsplit*.

In []:

c) Verwenden Sie den *DecisionTreeClassifier()*. Finden Sie heraus, wie Sie die Baumtiefe beschränken können. Erstellen Sie 3 Bäume und führen Sie alle Schritte für jeden Baum aus:

- einen kleinen Baum - stark beschränkt im Wachstum
- einen *mitteltiefen* Baum
- einen tiefen Baum, dessen Wachstum nicht beschränkt wurde

Trainieren Sie jeden Baum auf den Trainingsdaten.

In []:

d) Plotten Sie jeden Baum mit *_plottree*

In []:

e) Verwenden sie *predict* und lassen Sie sich für jeden Baum die Label für Trainings **und** Testdaten vorhersagen.

In []:

f) Berechnen Sie mit scikit-learn die Confusionmatrix und gängige Metriken wie Accuracy, MCC, Macro-Sensitivity und Macro-F1-Score.

In []:

g) Stellen Sie die Kenngrößen in einer Tabelle einander vergleichend gegenüber. Warum macht es Sinn, sich auch die Performance auf den Trainingsdaten anzuschauen?

In []:

Aufgabe 2: Bäume verstehen (15)

Basierend auf Aufgabe 1

a) Vergleichen Sie Ihre aufgestellten Bediingungen mit denen des Entscheidungsbaumes. Lassen Sie sich hierfür auch für jeden Baum die Feature-importance `feature_importances_` anzeigen.

In []:

b) Wie ist die Featureimportance für Entscheidungsbäume definiert (für Gini oder Entropie)?

c) Baumtiefen einschätzen

Basierend auf unterschiedlich tiefen Entscheidungsbäumen, erstellen Sie ein Diagramm mit der Performance (z.B. MCC) je Baum in Abhängigkeit von seiner Blattanzahl - erstellen Sie dafür mehr als 3 Bäume. Visualisieren Sie dabei beides, die Trainings- und die Testperformance.

In [47]:

e) Verwenden Sie die zwei wichtigsten Merkmale und Visualisieren Sie hier die Decision Surfaces für einen Baum mit under- bzw. over fitting (wandeln Sie hierfür z.B. den Code für die Decision Surfaces aus https://data-science-crashkurs.de/chapters/kapitel_07.html#decision-surfaces entsprechend ab).

In []:

f) Diskutieren Sie wieder den Bias-Variance Tradeoff an diesem Beispiel. Wo ist viel Bias, wo viel Variance? Wie sieht es mit over und underfitting aus?

In []:

Zusatzaufgabe: Featureimportance berechnen (10)

a) Verwenden Sie Ihren kleinen Baum von oben, oder erstellen Sie einen neuen kleinen Baum. Der Baum soll 2 bis 3 Entscheidungen treffen. Verwenden Sie als `criterion` *gini* (Standard) oder *entropy*. Visualisieren Sie ihn mit `plot_tree()`

In []:

b) Lassen Sie sich die Feature importance ausgeben

In []:

c) Berechnen Sie die Featureimportance von Hand und überprüfen Sie, ob Ihre Ergebnissen mit denen von b) übereinstimmen. Hinweis: Die für die Berechnung nötigen gini bzw. entropie Werte können Sie aus dem Baum in a) ablesen.

In []: