

Übung 2 - Explorative Datenanalyse

Aufgabe 1: Python besser kennenlernen (5)

Lesen Sie den Datensatz *citywealth.dat* in Python ein. Versuchen Sie den Datensatz zu verstehen, er enthält geschätzte Vermögen der Bewohner mehrerer Kleinstädte.

In []:

a) Lassen Sie sich mit `describe()` die wichtigsten Kenngrößen anzeigen - welche Gemeinsamkeiten und Unterschiede stellen Sie fest?

In []:

b) Visualisieren Sie die Verteilungen je Stadt durch ein Histogramm und vergleichend im Boxplot.

In []:

Aufgabe 2: Daten Skalieren (5)

Verwenden Sie die Daten aus Aufgabe 1.

a) Skalieren Sie die Daten je Stadt mittels z-Score Skalierung. (Hinweis: Bitte ohne die Verwendung eines Python-Scalers)

In []:

b) Lassen Sie sich wieder Histogramm und Boxplots anzeigen, was fällt Ihnen auf?

In []:

c) Verwenden Sie nun die min-max Normalisierung (wieder ohne vorgefertigte Pythonbibliotheken).

In []:

d) Erstellen und betrachten sie wieder Boxplots und Histogramme. Was fällt Ihnen auf?

In []:

Aufgabe 3: Verteilungen anpassen (5)

Erstellen Sie die gegebenen vier Verteilungen:

In [19]:

```
import numpy as np
```

In [20]:

```
dist_a=np.random.normal(loc=0.0, scale=1.0, size=1000)
dist_b=np.random.normal(loc=50, scale=3, size =1000)
dist_c=np.random.uniform(low=20,high=50,size=1000)
dist_d=np.random.uniform(low=10,high=100,size=1000)
dist_e = np.random.exponential(1.5, 1000)
```

a) Lassen Sie sich alle Verteilungen als Boxplot und Histogramm anzeigen

In []:

b) Lassen Sie sich QQ-Plots für alle Paare an Verteilungen anzeigen.

In []:

c) Führen Sie eine min-max-Skalierung auf den Daten aus und lassen Sie sich erneut Boxplots und Histogramme anzeigen. (Auch wenn es möglich wäre, verwenden Sie hierfür bitte nicht fertige Methoden wie den `MinMaxScaler` - Sie können aber im Anschluss mit ihm vergleichen)

In []:

d) Erstellen Sie für die min-max-Skalierten Werte QQ-Plots.

In []:

e) Erklären Sie die Ergebnisse.

In []:

Aufgabe 4: Skatterplots (5)

a) Lesen Sie den Datensatz *Kommissare.dat* in Phyton ein und speichern Sie ihn unter dem Objekt `kommissare` .

In []:

b) Visualisieren Sie die Attribute *Einkommen*, *Kontostand* und *Alter* in einem 3D-Scatterplot (Tipp: `mpl_toolkits.mplot3d Axes3D`) und einem `pairplot` (Tipp: `seaborn`). Färben Sie jeweils nach der Spalte Kreditklasse - was fällt Ihnen auf?

In []:

c) Führen Sie den unteren Code aus - stimmen die Regeln überein mit Ihren Beobachtungen?

In []:

```
import pandas as pd
import numpy as np
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn import tree
import matplotlib.pyplot as plt

# Unabhängige Variablen (Features) und abhängige Variable (Ziel)
X_part = kommissare[["Einkommen","Kontostand","Alter"]]
y_part = kommissare[["Kreditklasse"]]

# Aufteilen in Trainings- und Testdaten

# Erstellen und Trainieren des Entscheidungsbaums
clf = DecisionTreeClassifier(random_state=42)
clf.fit(X_part, y_part)

# Visualisieren des Entscheidungsbaums
plt.figure(figsize=(10, 8))
tree.plot_tree(clf, feature_names=["Einkommen","Kontostand","Alter"], class_names=["gut","schlecht"], filled=True)
plt.show()
```